基于深度神经网络的 RLC 串联电路实验数值曲线优化拟合

孙寒石（06219109）

（东南大学电子科学与工程学院，南京，210096）

摘 要： 利用深度神经网络对 RLC 串联电路实验中的数据处理所得的曲线进行优化拟合。通过训练网络参数和多次迭代，最后得出更加准确的实验结论。

关键词： RLC 串联电路的稳态响应；深度神经网络；数据处理；曲线拟合

Optimal Fitting of Numerical Curve of RLC Series Circuit Experiment Based on Deep Neural Network

Hanshi Sun

(Department of Electronic Science and Engineering, Southeast University, Nanjing 210096)

Abstract: A deep neural network is used to optimize and fit the curve obtained from the data processing in the RLC series circuit experiment. Through training network parameters and multiple iterations, more accurate experimental conclusions are finally drawn.

key words: steady-state response of RLC series circuit; deep neural network; data processing; curve fitting

一、引言

在 RLC 串联电路上加上一个正弦电压时，电路中的各元件上的电压会随着输入频率的改变而改变，回路电流和电源电压之间的相位差也会随之改变。前者是幅频特性，后者是相频特性。在 RLC 谐振电路中，当感抗等于容抗时，电路是纯电阻状态，发生串联谐振。

在实验中，对 RC，RL 串联电路的幅频特性和相频特性以及 RLC 谐振电路的相频特性和电流特性进行了探究。步骤中需要进行制图，由于实验数据的误差导致图解法所得出的结果与理论值有一定差距，于是需要对原始的数据进行曲线优化拟合，进而得到更准确的结果。

深度神经网络的灵感来自神经学。它模拟人脑的认知和表达过程，以及建立隐含关系的逻辑层次模型在学习数据中通过低层信号到高层特征的函数映射。与一般情况相比机器学习方法有浅层模型，深层学习有多重隐藏结构，更适合大数据处理。目前深度学习广泛应用于语音识别、自然语言处理、文字识别等领域[1]。

本文将利用 Tensorflow 架构构建神经网络，对实验数据进行进一步处理，多次迭代减小损失函数，最后完成拟合曲线的任务。最后会以理论值为标准，与原始的曲线进行比较讨论结果。

作者简介：孙寒石，2000 年，男，本科生，汉族，电子科学与技术专业，preminstrel@gmail.com

二、原理与方法

在 RLC 串联电路实验中，我们都选择了 20 个点来作图。由于数据的不准确性和较少的测量次数，导致所得出的曲线图与实际结果有一定偏差。在利用图解法取截止频率和谐振频率的时候，无法更精准地得到截止频率和谐振频率[2]。

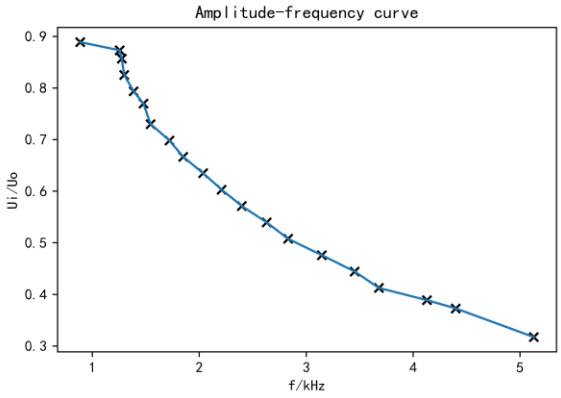

图 1 实验幅频曲线图 a

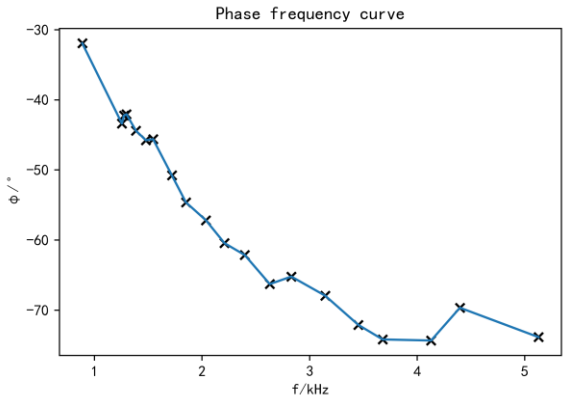

图 2 实验相频曲线图 a

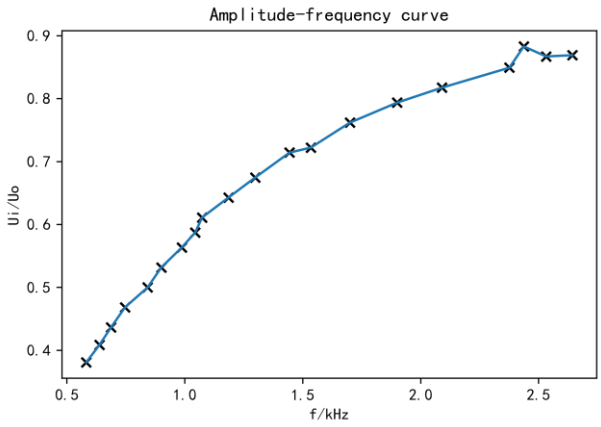

图 3 实验幅频曲线图 b

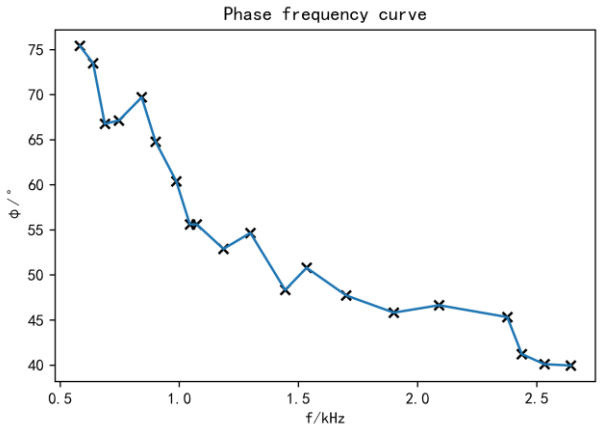

图 4 实验相频曲线图 b

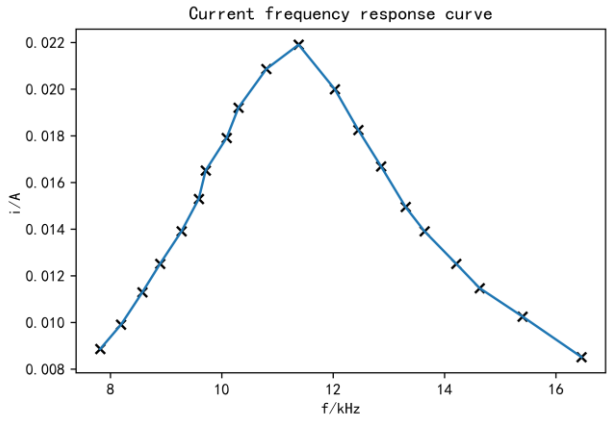

图 5 实验电流频响曲线图 c

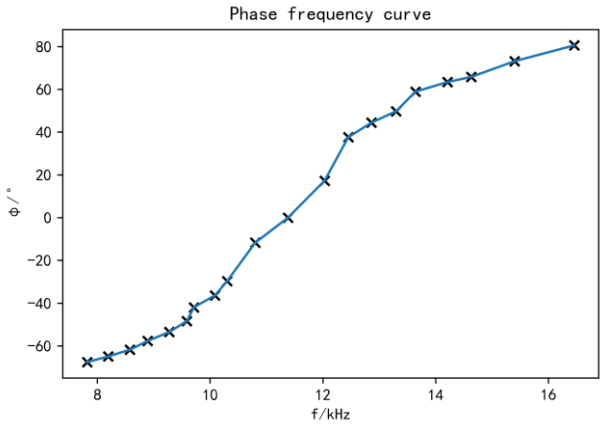

图 6 实验相频曲线图 c

利用神经网络进行多次迭代，可以不断减小损失函数的值，从而达到拟合曲线的效果。根据曲线的特性，我们可以选择 Tensorflow2 框架来搭建神经网络对曲线进行拟合。为了获得更多的训练集，可以对相邻实验数据之间的点进行等距线性取值，

这里每相邻数据之间取 300 个，共计 6000 个数据。经过多次测试，优化损失函数的方法使用梯度下降，学习速率选择 0.0001 的时候可以得出较好的拟合结果。同时，考虑到实验数据的误差，在每个数值上都增加了微量的 noise。本文仅选取 RLC 谐振实验相频曲线图 c 为例进行拟合并讨论分析所得结果。

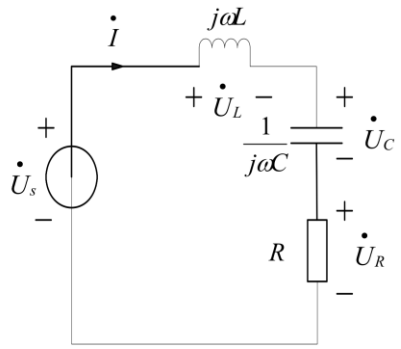

图 7 RLC 谐振实验电路图

电路如上图，电路阻抗为[3]：

$$Z = R + j(X_L - X_C) = R + j(\omega L - \frac{1}{\omega C}) \quad (1)$$

当 $\omega_0 L = \frac{1}{\omega_0 C}$ 时，即感抗等于容抗时，电路是纯电阻状态，发生串联谐振。谐振时，电流最大，并且相 ϕ 为 0。利用图解法可以得到 $\phi = 0$ 时的谐振频率 f_0 的值。

这里仅展示所用的部分代码：

```
x_data = np.linspace(f3[0],f3[1],300)
noise = np.random.normal(0, 0.05, x_data.shape)
y_data = np.linspace(varphi3[0],varphi3[1],300)+ noise
for i in range(1,19):
    x_data_temp= np.linspace(f3[i],f3[i+1],300)
    noise = np.random.normal(0, 0.05, x_data_temp.shape)
    y_data_temp=np.linspace(varphi3[i],varphi3[i+1],300)+ noise
    x_data= np.append(x_data,x_data_temp,axis=0)
    y_data= np.append(y_data,y_data_temp,axis=0)
plt.plot(x_data, y_data)
tf.disable_v2_behavior()
xs = tf.placeholder(tf.float32, [None, 1])
ys = tf.placeholder(tf.float32, [None, 1])
w1 = tf.Variable(tf.random_normal([1, 20]))
b1 = tf.Variable(tf.zeros([1, 20]) + 0.1)
ip1 = tf.matmul(xs, w1) + b1
out1 = tf.nn.relu(ip1)
w2 = tf.Variable(tf.random_normal([20,1]))
b2 = tf.Variable(tf.zeros([1, 1]) + 0.1)
ip2 = tf.matmul(out1, w2) + b2
out2 = ip2
loss = tf.reduce_mean(tf.reduce_sum(tf.square(ys-out2), reduction_indices=[1]))
train_step = tf.train.GradientDescentOptimizer(0.0001).minimize(loss)
init = tf.global_variables_initializer()
sess = tf.Session()
sess.run(init)
f3=f3.reshape((20,1))
varphi3=varphi3.reshape((20,1))
for i in range(20000):
    _, loss_value = sess.run([train_step, loss], feed_dict={xs:x_data, ys:y_data})
    if i%50==0:
        print(loss_value)
pred = sess.run(out2, feed_dict={xs:x_data})
```

```
plt.plot(x_data, pred,label="Original image")
plt.plot(f3,varphi3,label="Modified image")
plt.scatter(f3,varphi3,marker="x",color="black")
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus']=False
plt.title("Original image vs. Modified image")
plt.xlabel("f/kHz")
plt.ylabel(chr(966)+"/$^\circ$")
#plt.show()
plt.savefig("D:/Original image vs. Modified image.png",dpi=500,bbox_inches = 'tight')
```

三、结果与讨论

经过 20000 次迭代之后，能够得到效果较好的拟合曲线。可以看出，相比原始数据的曲线，更符合理论实际[4]。

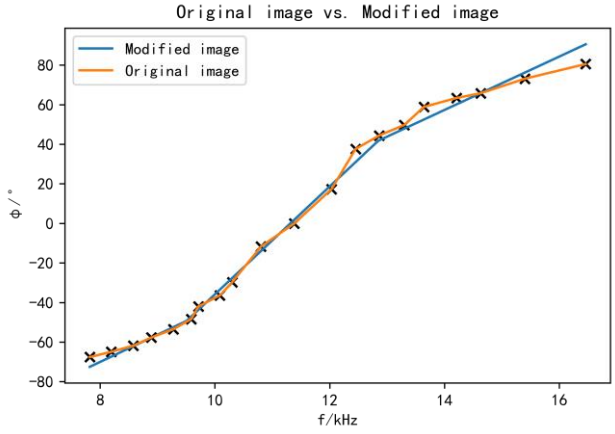

图 8 拟合修正后的曲线图

可以比较拟合修正后的曲线和原始数据对实验最终结果的影响。由公式 (1)，可以得到谐振频率的计算公式为：

$$\omega_0 = \frac{1}{\sqrt{LC}} \tag{2}$$

$$f_0 = \frac{\omega_0}{2\pi} = \frac{1}{2\pi\sqrt{LC}} \tag{3}$$

可以计算得到谐振频率的理论值为：

$$f_0^{Theoretical} = \frac{1}{2\pi\sqrt{10\times10^{-3}\times0.02\times10^{-6}}} = 11253.96Hz$$

根据实验原始数据得到的谐振频率理论值为：

$$f_0^{Experimental} = 11.38kHz$$

根据经过神经网络拟合曲线得到的谐振频率理论值为：

$$f_0^{Fitting} = 11275.98Hz$$

可以看到，很显然拟合后的曲线更接近理论值。值得注意的是，这里仅用了很简单的神经网络，如果想要达到更好的拟合效果，可以尝试更深层的神经网络，并优化损失函数。对于曲线拟合来说，为了防止梯度爆炸和梯度消失等事件发生，分批次训练也是一个很好的选择。

四、结论

本文对实验中的一个曲线利用神经网络进行了优化拟合，并使用拟合得到的曲线得出谐振频率。结果表明，相比于原始的曲线所得到的谐振频率，拟合之后的曲线更加准确。

但是由于训练集的数量极少，利用了线性插值来扩充训练集的方法，并增加噪声 noise，导致无法更好地完全发挥神经网络的优势。

参考文献：

[1] Goodfellow I , Bengio Y , Courville A . Deep Learning[M]. The MIT Press, 2016.

[2] 马文蔚等. 物理学(第五版). 北京：高等教育出版社，2006

[3] Lin Z , Hongbing W , Yida Z . Research and exploration on experimental method of RLC series resonance circuit[J]. Experimental Technology and Management, 2013.

[4] McKinney Wes. Python for data analysis[M]. 东南大学出版社, 2013.